

연세 프리미엄 인강

(입문) 바이트코딩의 한계를 부수자_클로드 코드_실전용 skills

2강 | GitHub에서 가져와 직접 크롤링

연세대학교 화학과 2020133048 정회광

CONTENTS

01. GitHub에서 찾기
02. git clone으로 가져오기
03. 설치하고 실행하기
04. 직접 크롤링하기

01

Day 2

GitHub에서 찾기

- 남이 만든 도구를 GitHub에서 찾는다
- `git clone`으로 내 컴퓨터에 가져온다
- 직접 실행해서 데이터를 뽑아낸다

git과 GitHub은 무엇인가

- git | 코드가 언제·어떻게 바뀌었는지 기록하는 도구
- GitHub | 그 기록을 인터넷에 올려 두는 창고
- 우리는 남의 창고에서 가져와 쓰고, 내 창고에 올려 관리한다

- github.com 에서 scraping 검색
- Star 수로 신뢰도를 가늠한다
- 최근 업데이트 날짜를 꼭 확인

Too many requests

You have exceeded a secondary rate limit.

Please wait a few minutes before you try again;
in some cases this may take up to an hour.

[Signing in](#) may provide a higher rate limit if you are not already signed in.

For more on scraping GitHub and how it may affect your rights, please review our
[Terms of Service](#).


GitHub 저장소 검색 결과

저장소 첫 화면 읽는 법

● D4Vinci / Scrapling

● Public | 누구나 볼 수 있다


● Code · Issues · Pull requests



D4Vinci / Scrapling

README가 곧 설명서

- 설치법과 예제가 여기 다 있다
- 복사해서 그대로 실행해 보면 된다
- 막히면 Claude Code에게 읽힌다



README 사용 예제


02

Day 2

git clone으로 가져오기

Code 버튼에서 주소 복사

- 초록색 Code 버튼을 누른다
- HTTPS 탭의 주소를 복사
- .../D4Vinci/Scrapling.git



Code 버튼에서 HTTPS 주소 복사

git clone 실행

- git clone 다음에 복사한 주소

- 폴더째 내 컴퓨터로 내려받는다

- 변경 이력까지 함께 따라온다

```
PS C:\work> git clone https://github.com/D4Vinci/Scrapling.git

Cloning into 'Scrapling'...
remote: Enumerating objects: 9601, done.
remote: Counting objects: 100% (104/104), done.
remote: Compressing objects: 100% (84/84), done.
remote: Total 9601 (delta 36), reused 44 (delta 18), pack-reused 9497 (from 1)
Receiving objects: 100% (9601/9601), 9.60 MiB | 10.30 MiB/s, done.
Resolving deltas: 100% (6735/6735), done.
```

git clone 실행 결과

03

Day 2

설치하고 실행하기

- 가상환경(venv)을 먼저 만든다

- `pip install "scrapling[fetchers]"`

- `[fetchers]` 없으면 못 쓴다

```
Using cached protego-0.6.2-py3-none-any.whl (10 kB)
Using cached tld-0.13.2-py2.py3-none-any.whl (296 kB)
Using cached w3lib-2.4.1-py3-none-any.whl (21 kB)
Using cached colorama-0.4.6-py2.py3-none-any.whl (25 kB)
Using cached pycparser-3.0-py3-none-any.whl (48 kB)
Using cached typing_extensions-4.16.0-py3-none-any.whl (45 kB)
Installing collected packages: w3lib, typing_extensions, tld, pycparser, protego,
  orjson, msgspec, lxml, idna, greenlet, cssselect, colorama, certifi, apify-finge
rprint-datapoints, scrapling, pyee, click, cffi, anyio, playwright, patchright, c
url_cffi, browserforge
Successfully installed anyio-4.14.2 apify-fingerprint-datapoints-0.15.0 browserfo
rge-1.2.4 certifi-2026.7.22 cffi-2.1.1 click-8.4.2 colorama-0.4.6 cssselect-1.5.0
  curl_cffi-0.16.0 greenlet-3.5.5 idna-3.19 lxml-6.1.2 msgspec-0.21.1 orjson-3.12.
0 patchright-1.62.1 playwright-1.62.0 protego-0.6.2 pycparser-3.0 pyee-13.0.1 scr
apling-0.4.14 tld-0.13.2 typing_extensions-4.16.0 w3lib-2.4.1
```

`curl_cffi` 까지 함께 설치된다

막히면 Claude Code에게

● "GitHub의 scrapling 쓰고 싶어"

● 저장소와 문서를 대신 읽어준다

● 환경 문제까지 짚어준다

> github의 scrapling 쓰고 싶어

- Fetch(<https://github.com/D4Vinci/Scrapling>)
 - └ Received 510KB (200 OK)

- Web Search("Scrapling python library 2026 latest version tutorial adaptive selectors")
 - └ Did 1 search in 8s

- Fetch(<https://pypi.org/pypi/scrapling/json>)
 - └ Received 115.6KB (200 OK)

Ran 2 shell commands

- 환경을 먼저 확인했습니다. Python 3.12.3은 있는데 pip와 ensurepip가 없는 상태입니다(우분투 기본 이미지). sudo 없이 해결되는 uv로 세팅하겠습니다.

- Running 2 shell commands · 12s...
 - └ \$ export PATH="\$HOME/.local/bin:\$PATH"
 - uv venv --python 3.12 2>&1 | tail -5

저장소를 대신 읽는 Claude Code

무엇이 되는지 정리받기

- 기능별 동작 여부를 표로 확인
- 정적 사이트는 지금 바로 가능
- 브라우저 필요한 기능은 추가 설치

무엇이 되고 무엇이 안 되나	
정적 사이트	○ 지금 바로
CSS 선택자	○ 지금 바로
여러 페이지	○ 지금 바로
브라우저 필요	X 추가 설치

설치 상태 점검

04

Day 2

직접 크롤링하기

- quotes.toscrape.com
- 크롤링 연습용으로 공개된 사이트
- 명언 · 저자 · 태그 구조

Quotes to Scrape

Login

*“The world as we have created it is a process of our thinking.
It cannot be changed without changing our thinking.”*

by **Albert Einstein** (about)

Tags: **change** **deep-thoughts** **thinking** **world**

크롤링 대상 페이지

- `Fetcher.get(주소)` 로 받아온다

- `status` 가 200이면 성공

- `css(...)[0].text` 로 값을 꺼낸다

```
[2026-08-20 04:53:04] INFO: Fetched (200) <GET https://quotes.toscrape.com  
> (referer: https://www.google.com/)  
status: 200  
10개 저장 -> quotes.csv
```

```
PS ...Wdemo> Get-Content quotes.csv -TotalCount 3
```

```
text,author,tags  
"The world as we have created it is a process of our  
" "It is our choices, Harry, that show what we truly
```

10개 인용문 추출 성공

표로 정리해서 뽑기

- .quote 를 하나씩 순회한다
- author·tags·text 를 따로 추출
- 10개의 행이 만들어진다

```
[2026-08-20 05:18:05] INFO: Fetched (200) <GET https://quotes.toscrape.co  
m/> (referer: https://www.google.com/)  
status: 200  
10개 저장 -> quotes.csv
```

```
PS ...Wdemo> python show_table.py
```

#	author	tags
1	Albert Einstein	change,deep-thoughts,thi
2	J.K. Rowling	abilities,choices
3	Albert Einstein	inspirational,life,live,
4	Jane Austen	aliteracy,books,classic,
5	Marilyn Monroe	be-yourself,inspirational
6	Albert Einstein	adulthood,success,value
7	André Gide	life,love
8	Thomas A. Edison	edison,failure,inspirati

구조화된 추출 결과

여러 페이지 + 파일 저장

- next 링크를 따라 3페이지까지

- 30행을 quotes.csv 로 저장

- 엑셀에서 바로 열린다

```
m/> (referer: https://www.google.com/)
1페이지 완료 - 누적 10행
[2026-08-20 05:18:11] INFO: Fetched (200) <GET https://quotes.toscrape.co
m/page/2/> (referer: https://www.google.com/)
2페이지 완료 - 누적 20행
[2026-08-20 05:18:12] INFO: Fetched (200) <GET https://quotes.toscrape.co
m/page/3/> (referer: https://www.google.com/)
3페이지 완료 - 누적 30행
총 30행 -> quotes_all.csv

PS ...Wdemo> (Get-Content quotes_all.csv).Count
31
```

3페이지 30행 → CSV

- robots.txt 와 이용약관을 먼저 본다
- 요청 간격을 두고 천천히 가져온다
- 개인정보 · 저작물은 수집하지 않는다

다음 시간 예고 : 창고가 대신 일한다

- GitHub은 코드를 보관만 하는 곳이 아니다
- GitHub Actions | 정해진 시간마다 내 코드를 대신 실행
- 3강에서 이 기능으로 알림봇을 24시간 돌린다